

## Taller 9 - Alineamientos múltiples y HMMs


### Grupo 04 - sección 02

#### Integrantes:

- Nicolas Montoya Leon - 202310678
- John Anderson Acosta - 202212004
- Raquel Bautista Escobar – 202310296

#### 1. Corriendo diferentes alineadores múltiples.

- Realice el alineamiento de ClustalOmega. Guarde el alineamiento y, seleccione FastA o ClustalW como formato de salida, asegúrese de cambiar el nombre del archivo de salida para evitar sobrescribir el archivo original.




Se observan en las **Figura A**, **Figura B** y **Figura C** los resultados generados por [EMBL-EBI](#) para el alineamiento progresivo (ClustalW o ClustalOmega). La **Figura A** indica los 21 alineamientos de las secuencias aminoácidos de las distintas especies. Asimismo, se percibe que la longitud de alineamiento, con gaps o espacios incluidos, es de 802 aminoácidos. Sumado a esto, la **Figura B** representa el Guide Tree del alineamiento, en el que se observa que hay 3 grandes grupos o clados que se formaron. Del mismo modo, la **Figura C** plasma el árbol filogenético del alineamiento, hay que aclarar que este no es un árbol filogenético de las relaciones evolutivas, sino una reconstrucción de las relaciones en base de las secuencias usadas. Finalmente, estos resultados son complementarios a los del alineamiento de salida del Clustal, y pueden ser encontrados y revisados con otros resultados que analizan otros apartados en [Results for Job ID: clustalo-I20240404-145644-0951-20423802-p1m](#) en la página de EMBL-EBI.

CLUSTAL O(1.2.4) multiple sequence alignment		
Patas	MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKSMLYKEEERSCPVCR	60
Colobus	MASGILVNIKEEVTCPICLELLTEPLSLHCGHSGFCQACITANHKSMLYKEGERSCPVCR	60
DLangur	MASGILVNIKEEVTCPICLELLTEPLSLHCGHSGFCQACITANHKSMLYKEGERSCPVCR	60
AGM_cDNA	MASGILVNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYKEEERSCPVCR	60
AGM	MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYKEEERSCPVCR	60
Tant_cDNA	MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYKEEERSCPVCR	60
Rhes_cDNA	MASGILLNVKEEVTCPICLELLTEPLSLHCGHSGFCQACITANHKESMLYKEEERSCPVCR	60
Baboon	MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHRKSMLYKEGERSCPVCR	60
Gibbon	MASGILVNVKEVTKTCPICLELLTQPQLSDCGHSGFCQACLTANHKTSMPD-EGERSCPVCR	59
Orangutan	MASGILVNVKEEVTCPICLELLTQPQLSDCGHSGFCQACLTANHKSTLD-KGERSCPVCR	59
Human	-MSGILVNVKEEVTCPICLELLTQPQLSDCGHSGFCQACLTANHKSMMD-KGESSCPVCR	58
Chimp	MASGILVNVKEEVTCPICLELLTQPQLSDCGHSGFCQACLTANHKSMMD-KGESSCPVCR	59
Gorilla	MASGILVNVKEEVTCPICLELLTQPQLSDCGHSGFCQACLTANHKSMMD-KGESSCPVCR	59
Howler	MASKILVNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKE----RERSCPLCR	55
Squirrel	MASRILGSIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKE-SMLH-QGERSCPLCR	59
Spider	MASEILLNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLH-QGERSCPLCR	59
Woolly	MASEILVNIKEEVTCPICLDDLLTEPLSLDCGHSGFCQACITADHKESTLH-QGERSCPLCR	59
Owl	MASRILVNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKSMMPH-QGERSCPLCR	59
PMarmoset	MASRILVNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLH-QGERSCPLCR	59
Titi	MASRILVNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLH-QGERSCPLCR	59
Saki	MASRILMNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKSMMH-QGERSCPLCR	59
* * * .:***:*****;***:**** *****:*****;*: * * * ***:*		
Patas	ISYQPENIQPNRHANIVEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDRKVICWLCE	120
Colobus	ISYQPENIRPNRHANIVANEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDRKVICWLCE	120
DLangur	ISYQPENIRPNRHANIV-KLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDRKVICWLCE	119
AGM_cDNA	ISYQPENIQPNRHANIVEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDSKVICWLCE	120
AGM	ISYQPENIQPNRHANIVEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDSKVICWLCE	120
Tant_cDNA	ISYQPENIQPNRHANIVANEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDSKVICWLCE	120
Rhes_cDNA	ISYQPENIQPNRHANIVANEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDSKVICWLCE	120
Baboon	ISYQPENIQPNRHANIVANEKLREVKLSPPEEGGLKVDHCARHGEKLLLFCQEDSKVICWLCE	120
Gibbon	ISYQHKNIRPNRHANIVANEKLREVKLSPPEEGQKVDHCARHGEKLLLFCQEDRKVICWLCE	119
Orangutan	VSYQPKNIRPNRHANIVANEKLREVKLSP-GQKVDHCARHGEKLLLFCQEDGKVICWLCE	118
Human	ISYQPENIRPNRHANIVANEKLREVKLSP-GQKVDHCARHGEKLLLFCQEDGKVICWLCE	117
Chimp	ISYQPENIRPNRHANIVANEKLREVKLSP-GQKVDHCAHHGEKLLLFCQEDGKVICWLCE	118
Gorilla	ISYQPENIRPNRHANIVANEKLREVKLSP-GQKVDHCARHGEKLLLFCQEDGKVICWLCE	118
Howler	VSYHSENLRPNRLHANIAERLREVMLSPEEEGQKVDRCARHGEKLLLFCQQHGNVICWLCE	115
Squirrel	LPHYSENLRPNRLHANIVERLREVRMLRPEERONVDHCARHGEKLLLFCQEDGNIICWLCE	119
Spider	VSYQSENLRPNRLHANIAERLREVMLSPEEEGQKVDRCARHGEKLLLFCQEDGKVICWLCE	119
Woolly	VGYQSENLRPNRLHANIAERLREVMLSPEEEGQKVDRCARHGEKLLLFCQEDGKVICWLCE	119
Owl	ISYSSENLRPNRLHVNIVERLREVMLSPEEEGQKVDHCAHHGEKLVLCQQDGNVICWLCE	119
PMarmoset	MSYPSENLRPNRLHANIVERLKEVMLSPEEEGQKVDHCARHGEKLLLFCQEDGKVICWLCE	119
Titi	ISYPSENLRPNRLHANIVERLREVVLSPPEEGQKVDLCARHGEKLLLFCQEDGKVICWLCE	119
Saki	ISYPSENLRPNRLHANIVERLREVMLSPEEEGQKVDHCARHGEKLLLFCQEDGKVICWLCE	119
: * :*:****:..*. ;*:*** * ** * ;***;***:***:: . :*****		
Patas	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
Colobus	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
DLangur	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDCDK	179
AGM_cDNA	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
AGM	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
Tant_cDNA	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
Rhes_cDNA	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
Baboon	RSQEHRGHHTFLMEEVAQEYHVKLQTALEMRLRQKQQAEAKLEADIREEKASWKIQTIDYDK	180
Gibbon	RSQEHRGHHTFLTEEVAQEYQMKLQQAALQMLRQKQQAEAEELADIREEKASWKTQIQTIDYDK	179
Orangutan	DSOFHDGHHTFLTEEVVAQEYHVKLQTALEMRLRQKQQAEAEELADIREEKASWKTQIQTIDYDK	178

Como se observa en la imagen de arriba, este es el resultado de salida para el alineamiento de Clustal Omega, se encuentra en formato ClustalW y, como se mencionó en los otros resultados proporcionados por EMBL-EBI, genera un alineamiento de 802 aminoácidos y se puede determinar que existen regiones, dominios y motivos que se conservan entre las especies para el gen TRIM5. No obstante, se observa que existen regiones en las que pocas secuencias fueron alineadas capaces de alinearse, lo que puede indicar que son regiones que solo se presentan en pocas especies o en ese organismo.

- Ahora, realice el alineamiento con T-Coffee. Cuando el procedimiento de alineamiento haya terminado será dirigido a una nueva página con enlaces a los archivos de salida. Guarde el alineamiento en formato Fasta o ClustalW en su computador.



De la misma manera que el resultado de Clustal Omega, en el caso de T-Coffee las **Figura A**, **Figura B** y **Figura C** son resultados generados por [EMBL-EBI](#) para el alineamiento basado en consistencias. La **Figura A** indica los 21 alineamientos de las secuencias aminoácidos de las distintas especies, en el que contrasta con Clustal Omega, al tener una longitud de 782. La **Figura B** representa el Guide Tree y la **Figura C** el árbol filogenético del alineamiento, cabe señalar que ambos árboles generaron una relación similar entre las especies, agrupando en categorías la mayoría de especies en su mayor parte de la misma forma. Finalmente, estos resultados pueden ser encontrados y revisados con otros resultados en [Results for Job ID: tcoffee-I20240404-150221-0227-7836564-p1m](#) en la página de EMBL-EBI.

```

CLUSTAL W (1.83) multiple sequence alignment

AGM      MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYK
AGM_cDNA MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYK
Baboon   MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHRKSMLYK
Chimp    MASGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHHKSMLDK
Colobus   MASGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHHKSMLYK
DLangur   MASGILNVNKEEVTCPICLELLTEPLSLHCGHSFCQACITANHKKSMLYK
Gibbon    MASGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHKTSMPE
Gorilla   MASGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHHKSMLDK
Howler   MASKILNVNKEEVTCPICLELLTEPLSLHCGHSFCQACITANHKKSMLDK
Human    M-SGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHHKSMLDK
Orangutan MASGILNVNKEEVTCPICLELLTQPQLSDCGHSFCQACLTANHHKSTLDK
Owl      MASRILNVNKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKKSMHQ
PMarmoset MASRILNVNKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLHQ
Patas    MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKKSMLYK
Rhes_cDNA MASGILLNVKEEVTCPICLELLTEPLSLHCGHSFCQACITANHKKSMLYK
Saki     MASRILMNKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKKSMHQ
Spider   MASEILNNIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLHQ
Squirrel  MASRILGSIKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKKSMHQ
Tant_cDNA MASGILLNVKEEVTCPICLELLTEPLSLPCGHSGFCQACITANHKESMLYK
Titi     MASRILNVNKEEVTCPICLELLTEPLSLDCGHSGFCQACITANHKESTLHQ
Woolly   MASEILNVNKEEVTCPICLDLTEPLSLDCGHSGFCQACITADHKESTLHQ
* * ** .:***:*****:***:***:*****:*****:***: * *

AGM      EEARSCPVCRISYQOPENIQPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
AGM_cDNA EEARSCPVCRISYQOPENIQPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Baboon   EGERSCPVCRISYQOPENIQPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Chimp    -GESSCPVCRISYQOPENIRPNRHVANIVEKLREVKLSPEEGQKVVDHCAAH
Colobus   EGERSCPVCRISYQOPENIRPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
DLangur   EGERSCPVCRISYQOPENIRPNRHVANIV-KLREVKLSPEEGQKVVDHCARH
Gibbon    -GERSCPVCRISYQHKNIRPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Gorilla   -GESSCPVCRISYQOPENIRPNRHVANIVEKLREVKLSPE-GQKVVDHCARH
Howler   -RERSCPCLCRVSYHSENLRPNRHLANIAERLREVMLSPEEGQKVDRCARH
Human    -GESSCPVCRISYQOPENIRPNRHVANIVEKLREVKLSPE-GQKVVDHCARH
Orangutan -GERSCPVCRVSYQPKNIRPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Owl      -GERSCPCLCRISYSSENLRPNRHLVNIVERLREVMLSPEEGQKVVDHCAAH
PMarmoset -GERSCPCLCRMSYPSSENLRPNRHLANIVERLKEMVLSPPEEGQKVVDHCARH
Patas    EEARSCPVCRISYQOPENIQPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Rhes_cDNA EGERSCPVCRISYQOPENIQPNRHVANIVEKLREVKLSPEEGQKVVDHCARH
Saki     -GERSCPCLCRISYPSSENLRPNRHLANIAERLREVMLSPEEGQKVVDHCARH
Spider   -GERSCPCLCRVSYQSENLRPNRHLASIVERLREVMLRPEERQNVHDHCARH
Squirrel  -GERSCPCLCRISYPSSENLRPNRHLANIVERLREVVLSPPEEGQKVDCARH
Tant_cDNA -GERSCPCLCRVGYQSENLRPNRHLANIAERLREVMLSPEEGQKVDRCARH
Titi     -GERSCPCLCRVGYQSENLRPNRHLANIAERLREVMLSPEEGQKVDCARH
Woolly   * *;*: * :*:*****:..*. :*;** * ** ;** ***:*
* *;*: * :*:*****:..*. :*;** * ** ;** ***:*



AGM      GEKLLLFCQEDSKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
AGM_cDNA GEKLLLFCQEDSKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
Baboon   GEKLLLFCQEDSKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
Chimp    GEKLLLFCQEDGKVICWLCLERSQEHRGHHFTLTEEVAREYQVKLQAALEM
Colobus   GEKLLLFCQEDRKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
DLangur   GEKLLLFCQEDRKVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Gibbon    GKKLLFCQEDGKVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Gorilla   GEKLLLFCQEDGKVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Howler   GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Human    GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Orangutan GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Owl      GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
PMarmoset GEKLLLFCQEDRKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
Patas    GEKLLLFCQEDRKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
Rhes_cDNA GEKLLLFCQEDSKVICWLCLERSQEHRGHHFTLMEEVAQEYHVKLQTALEM
Saki     GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Spider   GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Squirrel  GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Tant_cDNA GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Titi     GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
Woolly   GEKLLLFCQDHGNVICWLCLERSQEHRGHHFTLCEEVAQEYQVKLQAALEM
*;*:*****:.. :*****:***** * * ****. *; :***:.*

AGM      LRQQQQAEAKLEADIREEKASWKIqidydktnvsadfeqlreildweesn
AGM_cDNA LRQQQQAEAKLEADIREEKASWKIqidydktnvsadfeqlreildweesn

```

Por último, la última imagen representa el archivo de salida para el alineamiento de T-Coffee, se encuentra en formato ClustalW, posee un alineamiento de 782 aminoácidos y se puede concluir que existen 3 regiones o dominios que se presentan entre las especies para el gen TRIM5.

- Finalmente, realice el alineamiento en MUSCLE. Cargue su archivo de secuencias usando la opción Upload a file. Asegúrese que la salida esté en formato FastA o ClustalW.



Para el alineamiento en MUSCLE se obtuvieron los siguientes resultados **Figura A**, **Figura B** y **Figura C** generados por EMBL-EBI. La **Figura A** representa los 21 alineamientos múltiples de las secuencias aminoácidos de las distintas especies para un alineamiento iterativo. Igualmente, se percibe que el tamaño del alineamiento es de 802 aminoácidos. La **Figura B** muestra el árbol filogenético del alineamiento en MUSCLE, siendo muy similar al generado por Clustal Omega. Por último, la **Figura C** es el archivo de salida para el alineamiento de MUSCLE, se encuentra, al igual que los otros alineamientos, en formato ClustalW y de que hay 4 regiones o dominios para la secuencia en MUSCLE entre las especies para el gen TRIM5.

Bono [0.25 puntos] Realice el alineamiento desde el cluster con la línea de comandos (debe llamar el módulo muscle y el comando muscle, revise el manual para saber qué argumentos usar)

```
[biol2205@hypatia Grupo-04]$ module load muscle/5.1
[biol2205@hypatia Grupo-04]$ module list
Currently Loaded Modules:
 1) anaconda/conda4.12.0  2) muscle/5.1

[biol2205@hypatia Grupo-04]$ A


[biol2205@hypatia Taller-09]$ muscle -in TRIM5.fasta -clwout TRIM5.clw
MUSCLE v3.8.1551 by Robert C. Edgar
http://www.drive5.com/muscle
This software is donated to the public domain.
Please cite: Edgar, R.C. Nucleic Acids Res 32(5), 1792-97.

TRIM5 21 seqs, lengths min 492, max 709, avg 515
00:00:00 20 MB(-1%) Iter 1 100.00% K-mer dist pass 1
00:00:00 20 MB(-1%) Iter 1 100.00% K-mer dist pass 2
00:00:00 29 MB(-2%) Iter 1 100.00% Align node
00:00:00 29 MB(-2%) Iter 1 100.00% Root alignment
00:00:00 29 MB(-2%) Iter 2 100.00% Refine tree
00:00:00 29 MB(-2%) Iter 2 100.00% Root alignment
00:00:00 29 MB(-2%) Iter 2 100.00% Root alignment
00:00:00 29 MB(-2%) Iter 3 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 4 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 5 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 6 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 7 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 8 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 9 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 10 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 11 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 12 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 13 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 14 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 15 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 16 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 17 100.00% Refine biparts
00:00:00 29 MB(-2%) Iter 18 100.00% Refine biparts
00:00:01 29 MB(-2%) Iter 19 100.00% Refine biparts
00:00:01 29 MB(-2%) Iter 20 100.00% Refine biparts
C [biol2205@hypatia Taller-09]$
```


Para poder llevar a cabo el alineamiento desde el cluster fue necesario primero cargar el módulo **muscle/5.1**. **Figura A.** Posteriormente, ver los parámetros necesarios del comando **muscle**, para esto se apoyó usando el comando **-help** como se observa en la **Figura B**. Despues, se seleccionó el parámetro **-in** para introducir el archivo de entrada, que en este caso fue **TRIM5.fasta**, sumado a esto se usó el parámetro **-clwout**, para señalar que el archivo de salido es un Clustalw y no fasta. De igual forma, se agregó al archivo de salida el nombre **TRIM5.clw** como se observa en la **Figura C**. Finalmente se observa el archivo de salida, en el que primeramente resalta su gran similitud con el archivo de salida del alineamiento de MUSCLE en el punto anterior **Figura D**.

## 2. Comparando alineamientos múltiples.


- Usando JalView para comparar los resultados obtenidos en la parte A de ClustalOmega, T-Coffee y MUSCLE, mencione dónde comienzan y acaban las primeras tres regiones conservadas para cada algoritmo; indique las posiciones y qué tan largos son. Asuma que las regiones conservadas son de mínimo 10 aminoácidos de longitud.




En primer lugar se analizó las secuencias de forma separada, cada una en única ventana, es decir, en vez de comparar cada alineamiento por conjunto, se optó por comparar los tres algoritmos en su propio alineamiento, como se señala en la **Figura A**. En segundo lugar el método de comparación fue observar la calidad del alineamiento para decidir si es una región conservada, debido a que hay aminoácidos pudieron deberse a mutaciones pero que pertenecen aún al mismo grupo, por ejemplo básicos, ácidos, polares, apolares, etc.



La primera región conservada en Clustal Omega va de la posición 13 a la posición 23, teniendo una longitud de 11 aminoácidos seguidos, siendo una única secuencia en la especie Woolly monkey la que no corresponde en el alineamiento, en este caso la especie tiene el ácido aspártico (D) en vez del ácido glutámico (E). La segunda región va de la posición 30 a la posición 41 y posee 12 aminoácidos de longitud, sobre este caso se tiene que cuatro especies difieren del aminoácido isoleucina (I) por una Leucina (L). Por último, la última región conservada va de la posición 115 a la posición 128 y contiene 14 aminoácidos, al igual que los anteriores regiones, hay un cambio en la especie Howler del aminoácido Glutamina(Q) por el Ácido glutámico(E). Sin el caso de que fuera estrictamente una región seguida para todas las especies, sólo habría una región conservada en la posición 378 hasta la posición 388.



La primera región conservada en T-Coffee va de la posición 13 a la posición 23, teniendo una longitud de 11 aminoácidos seguidos, siendo una única secuencia en la especie Woolly monkey la que no corresponde en el alineamiento, al igual que en Cluster Omega. La segunda región va de la posición 30 a la posición 41 y posee 12 aminoácidos de longitud, sobre este caso se tiene en este caso cinco especies difieren del aminoácido isoleucina (I) por una Leucina (L). Por último, la última región conservada, al igual que las otras dos, va de la posición 115 a la posición 128 y contiene 14 aminoácidos, una gran similitud que comparte con Cluster Omega. No obstante, en algo que contrasta es que en el caso de que fuera estrictamente una región seguida para todas las especies, sólo habría una región conservada en la posición 573 hasta la posición 582, siendo de una región de longitud de 10 aminoácidos.



Al igual que en las otras tres secuencias anteriores, el alineamiento al usar MUSCLE también posee 3 regiones conservadas en las posiciones 13 a la posición 23, en la posición la posición 30 a la posición 41 y en la posición posición 115 a la posición 128, teniendo las mismas causas de los mismatches presentes en las especies iguales. Algo que tiene relación con Cluster Omega y que contrasta con T-Coffee, es que posee en el caso de que fuera estrictamente una región

seguida de aminoácidos para todas las especies, sólo habría una región conservada en la posición 378 hasta la posición 388.

- ¿Qué modificaciones se podrían hacer a los alineamientos? ¿Hay alguna(s) secuencia(s) que se podría(n) eliminar?


Como se ha mencionado anteriormente, la secuencias Woolly monkey y Howler generan mismatches en el momento de alinear las 21 secuencias de las especies, algo que si se modificara o se eliminará produciría un efecto en que las regiones conservadas fueron para todas las especies sin ninguna excepción y teniendo una conservación del 100% para todo el alineamiento múltiples para cada uno de los tres algoritmos.

- ¿Qué métodos de alineamientos presentan las mayores diferencias entre sí? ¿Qué métodos presentan las menores? Explique basado en la metodología de cada algoritmo sus resultados.

Los alineamientos que poseen las mayores diferencias serían Cluster Omega con T-Coffee y MUSCLE con T-coffee, y del mismo modo, los alineamientos que presentan las menores diferencias es MUSCLE y Cluster Omega, esto se podria explicar debido a que tanto Cluster Omega como MUSCLE son alineamientos progresivos o iterados, un alineamiento muy similar que no tienen muchas diferencias en reads muy cortos, al contrario de T-Coffee basado en consistencias.

### 3. Perfiles de HMMs y homologías.

- Busque en la carpeta ~/Talleres/Taller-04 el archivo de nombre Group\_11.fasta. Realice un alineamiento múltiple con MUSCLE, guarde el archivo en formato fasta. El alineamiento se puede hacer en la herramienta web del EBI o en el módulo en el clúster.



- Construya el HMM para nuestras secuencias problema Group\_11.fasta, estas serán usadas como señuelo para atrapar los receptores olfativos de interés en el grupo generalista de receptores. Esto debe hacerlo desde el clúster llamando el módulo hmmer y usando el comando con los siguientes argumentos.

**hmmbuild** perfil.hmm alineamiento.fasta

```
[biol2205@hypatia Grupo-04]$ hmmbuild Group11.hmm Group_11_aligned.fasta
# hmmbuild :: profile HMM construction from multiple sequence alignments
# HMMER 3.4 (Aug 2023); http://hmmer.org/
# Copyright (C) 2023 Howard Hughes Medical Institute.
# Freely distributed under the BSD open source license.
#
# -----
# input alignment file:          Group_11_aligned.fasta
# output HMM file:             Group11.hmm
#
#
# idx name                  nseq  alen  mlen eff_nseq re/pos description
#-----
1   Group_11_aligned        43    283   185     1.33   0.591
#
# CPU time: 0.17u 0.00s 00:00:00.17 Elapsed: 00:00:00.19
```


- Ahora realizaremos la búsqueda en la base de datos general (OBP\_ALL\_1.fasta). Para eso use el siguiente comando:

**hmmsearch** perfil.hmm base\_datos.fasta > salida search.out

Los resultados restantes tendrán tres partes, donde la primera parte contiene aquellas secuencias que fueron rescatadas y sus respectivos mejores dominios. De acuerdo con lo que conoce sobre el e-value, ¿piensa que los resultados son confiables?

```
Internal pipeline statistics summary:
-----
Query model(s):                      1  (185 nodes)
Target sequences:                    2736  (431750 residues searched)
Passed MSV filter:                  2019  (0.737939); expected 54.7 (0.02)
Passed bias filter:                 1526  (0.557749); expected 54.7 (0.02)
Passed Vit filter:                  904   (0.330409); expected 2.7 (0.001)
Passed Fwd filter:                  451   (0.164839); expected 0.0 (1e-05)
Initial search space (Z):           2736  [actual number of targets]
Domain search space (domZ):         451   [number of targets reported over threshold]
# CPU time: 1.11u 0.02s 00:00:01.13 Elapsed: 00:00:00.70
```

- Ahora para la visualización de los HMMs se hará en forma de logos. Esto puede realizarse en el enlace [Skylight](#). Use la aplicación y genere el logo correspondiente para perfil generado con HMMer (perfil.hmm). Explique ¿Qué significa un logo? ¿Qué información puedo extraer de él?



Los logos son representaciones gráficas de la información contenida en perfiles HMM; estos muestran la probabilidad de ocurrencia de cada aminoácido o nucleótido en cada posición del alineamiento múltiple. Las posiciones del alineamiento se representan en columnas, donde la altura de las letras en cada columna indica la frecuencia relativa de cada aminoácido o nucleótido en esa posición.


Mediante los logos es posible obtener información sobre la conservación de las diferentes regiones de las secuencias alineadas, siendo aquellas que tienen letras más altas, las más conservadas dado que dicho nucleótido se repite más.

- Describa biológicamente, qué significa este resultado con respecto a la pregunta biológica sobre los receptores olfativos de los insectos.

A partir del análisis tanto del alineamiento múltiple, como del logo obtenido del archivo .hmm, se puede evidenciar la presencia de múltiples regiones homólogas; lo cual es un indicativo positivo para existencia de regiones olfativas específicas dentro de grupo de insectos, que les permitirían detectar el olor a flores.

#### **4. Analizando dominios y familias de proteínas.**

Descargue el archivo RHLR.fasta del directorio ~/Talleres/Taller-09 del cluster y utilice InterPro para identificar todos los dominios o motivos que tenga esta proteína. ¿Cuántos dominios y superfamilias homólogas encontró? ¿En qué posiciones? ¿Qué funciones reportadas poseen estas regiones?



1 - 5 of 5 entries matching InterPro

ACCESSION	NAME	SOURCE DATABASE	MATCHES
IPR005143	Transcription factor LuxR-like, autoinducer-binding domain	InterPro	100 200
IPR036693	Transcription factor LuxR-like, autoinducer-binding domain superfamily	InterPro	100 200
IPR036388	Winged helix-like DNA-binding domain superfamily	InterPro	100 200
IPR000792	Transcription regulator LuxR, C-terminal	InterPro	100 200
IPR016032	Signal transduction response regulator, C-terminal effector	InterPro	100 200

Se encontraron 11 dominios, de los cuales los más representativos son Autoind\_bind y HTH\_LUXR\_2 en las posiciones 25-164 y 174-239. Por otra parte, se presentan 7 superfamilias homólogas, en las posiciones 3-177 y 171-240-

#### Funciones reportadas:

- Procesos biológicos: regulación de la transcripción con plantilla de ADN (GO:0006355)
- Función molecular: vinculante de ADN (GO:0003677)

<https://www.ebi.ac.uk:443/interpro//result/InterProScan/iprscan5-R20240410-153327-0112-94670255-p1m/>